PROJET DE RECHERCHE D'INFORMATION

PHASE 1

Interface administrateur d'indexation dynamique

Guide d'utilisation et de démonstration

Version mise à jour — novembre 2026

Objectif du guide

Ce document accompagne le rapport technique et explique comment exécuter une démonstration de l'application. Il décrit les contrôles de l'interface et le contenu des fichiers exportés.

1. Préparer l'environnement

Depuis PowerShell, dans le dossier du projet :

```
python -m pip install numpy scikit-learn
python main.py
```

Tkinter est fourni avec la plupart des installations Python pour Windows. Si le terminal signale qu'une bibliothèque est absente, installer les dépendances dans le même environnement Python que celui utilisé pour démarrer main.py.

2. Charger les documents

Choix	Action
Reuters SGML/XML	Sélectionner un dossier qui contient les fichiers .sgm. test_docs est fourni pour l'essai.
Reuters CSV	Sélectionner un seul fichier CSV; il doit contenir une ligne d'en-têtes et une colonne de texte reconnue.
Nombre maximal	Choisir une valeur puis cliquer sur Recharger les documents.
Aperçu	Ouvrir Aperçu des documents; sélectionner une ligne pour voir l'article complet.

3. Configurer le pipeline

Cocher les traitements souhaités. Les flèches changent l'ordre; Réinitialiser rétablit la configuration initiale. Stemming et lemmatisation ne peuvent pas être cochés ensemble. Aperçu étape par étape montre le texte brut puis le résultat de chaque étape active.

Pour illustrer la normalisation, indexer avec cette seule étape, puis chercher OIL! dans l'aperçu des postings : la requête est transformée en oil. Toute modification du pipeline nécessite de générer les index à nouveau.

4. Générer et interpréter les index

Cliquer sur Générer les Index. Le résumé affiche le nombre de documents, la taille du vocabulaire, le temps et la mémoire estimée. Le tableau compare BoW, F, TF et TF-IDF sous forme de deux matrices et de listes inversées. Le rapport matrices/liste donne un aperçu comparatif, pas une mesure complète de RAM système.

Modèle	Interprétation simple
BoW	Le terme est présent (1) ou absent (0).
F	Nombre d'occurrences du terme dans chaque document.
TF	Fréquence brute divisée par la fréquence la plus élevée du document.
TF-IDF	Fréquence TF pondérée par la rareté du terme dans tout le corpus.

5. Exporter les résultats

Cliquer sur Exporter les Index (.zip), choisir un format et sélectionner l'emplacement du fichier ZIP. Les trois formats incluent config.json, vocabulaire.txt et ids_documents.txt; ils contiennent aussi les structures d'index dans leur format propre.

Format	Quand le choisir
JSON — lisible	Pour inspecter les valeurs et échanger avec un programme qui lit JSON.
Texte — matrices et postings	Pour examiner les lignes de matrices et les listes inversées dans un éditeur.
Binaire — compact	Pour conserver les structures Python/NumPy et les recharger plus rapidement.

Un fichier index.pkl est binaire : ne pas l'ouvrir avec le Bloc-notes. Pour le format binaire, extraire l'archive et charger le dossier qui contient le pickle avec le code Python correspondant. Ne jamais charger un pickle d'une source inconnue.

6. Enregistrer les paramètres pour la phase suivante

Le bouton Publier les paramètres demande une limite maximale et enregistre localement publication.json. Le fichier mémorise le type et le nom de la source, le pipeline actif et la limite. Il ne rend pas les paramètres accessibles sur Internet et n'ajoute pas d'authentification.

7. Déroulé conseillé devant l'enseignant

Temps	Démonstration
1 min	Présenter la séparation des modules et charger le jeu test_docs.
1 min	Ouvrir un document et expliquer l'ordre du pipeline.
1 min	Montrer l'aperçu étape par étape et comparer les tokens avant/après.
1 min	Générer les quatre modèles et expliquer une ligne du tableau mémoire.
1 min	Rechercher oil, exporter un ZIP et montrer config.json.

Questions courantes

Pourquoi la liste inversée? Elle associe chaque terme aux documents où il apparaît, ce qui évite de parcourir tous les zéros d'une matrice pour ce type d'accès.
Pourquoi deux matrices? Ce sont les mêmes poids avec les axes transposés.
La publication est-elle en ligne? Non, elle écrit seulement un fichier JSON local.
La recherche est-elle déjà la phase 2? Non, la zone de mot vérifie seulement les postings TF-IDF; elle ne classe pas une requête complète par similarité.

Ce guide correspond aux fonctions présentes dans la version actuelle du projet.