PROJET DE RECHERCHE D'INFORMATION

PHASE 1

Interface administrateur d'indexation dynamique

Rapport technique et fonctionnel destiné à l'évaluation

Version mise à jour — novembre 2026

Résumé

Ce rapport décrit un outil d'administration de première phase pour préparer un corpus de recherche d'information. L'application charge Reuters sous forme de fichiers SGML/XML ou de CSV, permet de choisir et d'ordonner les étapes de prétraitement, construit quatre modèles d'indexation et fournit des mesures de mémoire et des exports réutilisables.

Périmètre exact : l'option « Publier les paramètres » écrit un fichier JSON local. Elle ne déploie pas l'application sur un serveur et ne crée pas de comptes utilisateurs. La recherche côté client et le classement Top-K relèvent de la phase suivante.

1. Objectifs et conformité au cahier des charges

Attendu Phase 1	Réalisation
Charger des données Reuters	Sélection d'un dossier .sgm ou d'un fichier CSV avec colonnes texte reconnues.
Configurer le prétraitement	Étapes activables, ordre modifiable, réinitialisation et aperçu sur un document.
Générer plusieurs modèles	BoW, F, TF et TF-IDF avec deux matrices et une liste inversée par modèle.
Mesurer les résultats	Documents, vocabulaire, durée, taille mémoire des formats et comparaison de structures.
Sauvegarder et transmettre	Export ZIP configurable en JSON, texte ou binaire, avec vocabulaire, IDs et configuration.

2. Architecture du programme

Module	Responsabilité
main.py	Démarre l'application.
gui.py	Interface Tkinter, validation des entrées, coordination des fonctions et affichage.
chargement.py	Lecture Reuters SGML et CSV, extraction des identifiants et textes.
pretraitement.py	Nettoyage, normalisation, stopwords, stemming et lemmatisation manuels.
indexation.py	Comptage des fréquences, calcul des modèles, matrices, postings et métriques.
stockage.py	Export ZIP multi-format et écriture des paramètres de publication locale.

Le flux est : source → documents identifiés → pipeline NLP → tokens → index → statistiques et export. La séparation en petits modules permet de distinguer l'interface des transformations et des calculs.

3. Chargement et aperçu des documents

L'administrateur choisit soit un dossier de fichiers Reuters .sgm, soit un fichier CSV. Le chargeur SGML extrait NEWID, TITLE et BODY. Le chargeur CSV reconnaît une colonne d'identifiant facultative et des colonnes de texte telles que title, headline, text, body, content, article ou description. Si aucun identifiant n'est fourni, un numéro de ligne sert d'identifiant. Un maximum de documents peut être fixé avant le chargement.

La fenêtre « Aperçu des documents » affiche jusqu'à 100 articles chargés; sélectionner une ligne montre le texte associé. Le bouton de rechargement relit la source avec la limite courante.

4. Pipeline de prétraitement

Étape	Description et choix de réalisation
Nettoyage des balises	Supprime les balises SGML/XML à l'aide d'une expression régulière.
Normalisation	Minuscules, ponctuation et chiffres remplacés par des espaces.
Stopwords	Liste anglaise définie directement dans le code; retrait des mots de fonction fréquents.
Stemming	Règles pédagogiques de suffixes pour réduire certaines formes à une racine.
Lemmatisation	Règles de suffixes et petit dictionnaire d'exceptions; résultat approximatif.

Stemming et lemmatisation sont exclusifs dans l'interface, car ce sont deux traitements alternatifs des formes des mots. L'aperçu étape par étape applique les étapes actives à un document choisi et affiche le nombre de mots et un extrait après chaque transformation.

Limite linguistique : le stemming et la lemmatisation sont des implémentations manuelles simplifiées. Elles sont faciles à expliquer mais ne reproduisent pas un lemmatiseur fondé sur un dictionnaire grammatical complet.

5. Modèles et structures d'index

Modèle	Formule / règle	Sens
BoW	1 si F(t,d) > 0, sinon 0.	Présence ou absence.
F	Nombre d'occurrences F(t,d).	Fréquence brute.
TF	F(t,d) / fréquence maximale du document.	Fréquence relative au document.
TF-IDF	TF(t,d) × log(N / df(t)).	Diminue le poids des termes fréquents dans le corpus.

N désigne le nombre de documents et df(t) le nombre de documents contenant le terme. CountVectorizer construit le vocabulaire et le tableau de fréquences; NumPy réalise les transformations numériques. La formule TF-IDF est appliquée explicitement avec le logarithme non lissé.

Structure	Orientation ou contenu
matrice_terme_doc	N lignes de documents × M colonnes de termes.
matrice_doc_terme	M lignes de termes × N colonnes de documents (transposée).
liste_inversee	terme → [(identifiant document, poids)]; seules les valeurs non nulles sont retenues.

6. Métriques, export et paramètres de publication

Les matrices sont stockées en float32. La taille affichée d'une matrice utilise son attribut nbytes. La taille de la liste inversée est estimée en additionnant les tailles rapportées par sys.getsizeof pour le dictionnaire, les termes, les listes et les tuples. La mémoire totale additionne les structures comptabilisées pour les quatre modèles.

L'estimation Python n'est pas une mesure complète du processus : tous les objets référencés ne sont pas comptés individuellement. Les valeurs sont utiles pour comparer les structures dans les mêmes conditions; elles ne doivent pas être interprétées comme une mesure exacte de la RAM du système.

Format d'export	Contenu de l'archive ZIP
JSON	index.json avec les deux matrices et les postings, config.json, vocabulaire.txt, ids_documents.txt.
Texte	Matrices TSV et listes inversées TSV, plus configuration, vocabulaire et IDs.
Binaire	index.pkl, plus configuration, vocabulaire et IDs.

Le format binaire est compact et doit être lu par Python; le JSON et les fichiers texte sont inspectables. Pour un corpus volumineux, l'export JSON peut produire une archive plus grande que l'export binaire.

« Publier les paramètres » enregistre publication.json avec le type/nom de source, le pipeline courant et une limite maximale, choisie entre 1 et 1000 documents. C'est une publication locale de configuration destinée à préparer une phase client; il n'existe pas encore de serveur, d'authentification ou de déploiement distant.

7. Vérifications et limites

Vérification	Résultat
Compilation	Les modules Python de l'application se compilent sans erreur.
Chargement Reuters fourni	Le fichier d'exemple .sgm est lu et fournit 5 documents.
CSV de test	Lecture des en-têtes, séparateurs, limite de documents et indexation testées sur un CSV temporaire.
Exports	Archives JSON, texte et binaire vérifiées; présence des paramètres, vocabulaire et IDs contrôlée.
Publication locale	Le JSON des paramètres et la limite sont vérifiés après écriture.

Limites restantes

Les matrices sont denses et peuvent consommer beaucoup de mémoire sur tout le corpus; l'indexation s'exécute dans le thread de l'interface et peut donc la bloquer pendant un calcul long. Le CSV attendu doit avoir des en-têtes reconnus. La publication ne configure pas réellement un serveur. Il n'y a pas de bouton GUI pour réimporter un index, ni de recherche utilisateur par similarité cosinus dans cette phase.

8. Installation et démonstration

Installer NumPy et scikit-learn, puis lancer python main.py depuis le dossier du projet. Pour une démonstration reproductible, charger test_docs, consulter un article, montrer le pipeline étape par étape, générer les index, rechercher oil, puis exporter une archive dans chacun des formats proposés.

Conclusion

La phase livrée couvre le cycle d'administration demandé : acquisition des documents, paramétrage du prétraitement, génération de modèles, observation de métriques et sauvegarde. Les fonctionnalités ajoutées rendent l'expérimentation plus visible, tandis que les limites indiquent clairement ce qui reste à développer pour une phase de recherche utilisateur.

Captures d'écran à insérer avant remise finale si elles sont exigées par l'enseignant.